בס"ד

קישורים להורדה נמצאים בתוך ה README וכן גם הסבר איפה לשים כל קובץ כחלק מההכנה לריצה

המבנים והפורמטים של הקבצים והדאטה סט מצויינים ב README

חלק ראשון

1. **הגורמים האפשריים לאיטיות העברת קבצים הם:**

- רוחב פס נמוך : רוחב פס מייצג כמה נתונים ניתן להעביר בפרק זמן מסוים. במידה ורוחב הפס נמוך ההעברה תיהיה איטית מכיוון שלא ניתן להעביר הרבה נתונים בזמן קצר. רוחב פס נמוך נגרם ממספר סיבות, לדוגמא, מגבלה של ספק האינטרנט, כאשר כמה מכשירים מחוברים באותו זמן, חיבור חלש וכו'...
- עיכובים ברשת : מרחק פיזי, עומס על הרשת ופרוטוקולים איטיים (כגון TCP) גורמים בין היתר לעיכובים ברשת.
- אובדן חבילות : בעיות ברשת, הפרעות רשת או חיבור אינטרנט לא יציב, יכולים לגרום למצב של איבוד חבילות ואי הגעתן ליעד.
- בעיות ברשת : בעיות כלליות שיכולות לנבוע מבעיות חומרה.

איך היינו מנתחים כל בעיה?

- בדיקת רוחב פס – ננסה להעביר קובץ קטן ונבדוק מהי המהירות המתקבלת בפועל, אם המהירות קטנה מאוד ביחס למהירות רוחב הפס המצופה אז ייתכן והתקלה ברוחב הפס.
- בדיקת עיכובים- שימוש בפקודת ping כדי לבדוק זמן תגובה, תוצאה עם זמן תגובה גבוה או פערים משמעותיים בזמנים מעידה על עיכובים ברשת.
- בדיקת אובדן חבילות – להשתמש בוואירשרק כדי לבדוק אובדן חבילות, לאחר לכידת תעבורה הוא מציג את כל החבילות שנלכדו ואז ניתן לחפש הודעות שגיאה המצביעות על חבילות שאבדו או לבדוק אם יש חור ברצף המספרים של ה "sequence numbers".
אם אין הודעות שגיאה על חבילות שאבדו, אפשר לבדוק ב-Wireshark אם יש TCP Retransmissions, כלומר חבילות שנשלחו מחדש כי הן לא התקבלו. אם הפינג מראה זמן תגובה גבוה אבל אין אובדן חבילות, ייתכן שהבעיה היא עומס ברשת או רוחב פס נמוך.
- בעיות ברשת- בדיקת עומס על השרת (דרך מנהל משימות וכו'...)

2. ההשפעה של מנגנון בקרת הזרימה של TCP היא שהוא מוודא שהשולח לא ישלח יותר נתונים ממה שהמקבל יהיה מסוגל לעבד. מה שמאפשר זאת זה באמצעות חלון בקרת הזרימה שמוגדר על ידי המקבל. כאשר למעביר יש כוח עיבוד גבוה משמעותית מהמקבל אז השולח עשוי לשלוח נתונים בקצב גבוה יותר ממה שהמקבל מסוגל לעבד וזה יגרום להקטנת חלון בקרת הזרימה. ובסופו של דבר השולח יאלץ לחכות עד שהמקבל יוכל לעבד את הנתונים שנשלחו מה שיגרום להאטה בקצב ההעברה הכולל.
אם רוצים לראות איך בקרת הזרימה משפיעה בפועל, אפשר לבדוק האם גודל החלון משתנה בWireshark-אם החלון מצטמצם מאוד אחרי מספר קטן של חבילות, זה סימן שהמקבל מתקשה לעבד את הנתונים, מה שגורם להאטה בקצב ההעברה.

3. תפקיד הניתוב ברשת הוא תהליך בחירת הנתיב שדרכו יעברו הנתונים מהרשת המקורית ליעד.
בחירת הנתיב משפיעה על ביצועי הרשת בכך שלדוגמא בחירת נתיב קצר עשוי להקטין את זמן התגובה ולהגדיל את קצב ההעברה, בנוסף, נתיב עם פחות עומס עשוי להקטין את אובדן החבילות ולהגדיל את אמינות ההעברה.
גורמים שיש לקחת בחשבון בהחלטות ניתוב:
- אורך הנתיב :מספר הקפיצות (hops) בין המקור ליעד.
- עומס על הנתיב :כמות התעבורה שעוברת בנתיב.
- אמינות הנתיב :שיעור אובדן החבילות בנתיב.
- זמן תגובה :זמן התגובה הכולל של הנתיב.

אם רוצים לבדוק איזה חלק מהמסלול גורם להשהיות, אפשר להריץ פקודה שמראה את כל התחנות בדרך לשרת ולראות היכן מתרחשים עיכובים משמעותיים. אם אחת התחנות מציגה זמן תגובה גבוה מאוד, זה יכול להצביע על עומס באותו נתב.

4. MPTCP מאפשר שימוש במספר נתיבים להעברת נתונים בין המקור ליעד.
זה משפר את ביצועי הרשת על ידי ניצול טוב יותר של רוחב הפס הזמין והקטנת העומס על נתיב יחיד. הוא גם מגביר את האמינות על ידי מתן אפשרות להעברת נתונים בנתיב חלופי במקרה של כשל בנתיב הראשי.

השימוש ב MPTCP שימושי במיוחד כשיש כמה חיבורים זמינים, למשל, כאשר מחשב מחובר גם לוויפי וגם לרשת סלולרית. זה מאפשר ניצול טוב יותר של רוחב הפס ומונע מצב שבו תעבורה מנותבת רק לנתיב אחד שיכול להיות עמוס.

5. סיבות אפשריות לאובדן חבילות:
עומס יתר על הנתבים- נתבים עמוסים עשויים לאבד חבילות.
בעיות חומרה- תקלות בציוד הרשת.
בעיות תוכנה- תקלות בתוכנת הניתוב.
הגדרות שגויות- הגדרות ניתוב או QoS שגויות.

צעדים לפתרון הבעיה:
בדיקת עומס על הנתבים- צריך לנתר את עומס העבודה על הנתבים ואז להקטין אותו במידת הצורך.
בדיקת חומרה- צריך לבדוק את ציוד הרשת ולהחליף רכיבים פגומים.
עדכון תוכנה : לעדכן את תוכנת הניתוב לגרסה האחרונה.
בדיקת הגדרות : לבדוק את הגדרות הניתוב ו QoS-ולתקן שגיאות.

בס"ד

חלק שני

Early Traffic Classification With Encrypted ClientHello: A Multi-Country Study

תרומת המאמר:

המאמר מציג תרומה משמעותית בתחום סיווג התעבורה המוצפנת, במיוחד בתרחיש שבו נעשה שימוש בפרוטוקול "Encrypted Client Hello" (ECH). המחקר מתמקד בפיתוח אלגוריתם חדש הנקרא hybrid Random Forest Traffic Classifier (hRFTC) - מטרתו לשפר את היכולת לסווג תעבורה כבר בשלבים מוקדמים, תוך התמודדות עם האתגרים שמציב פרוטוקול ההצפנה TLS 1.3 וגרסאותיו המתקדמות.

האלגוריתם משלב בין תכונות בלתי מוצפנות מלחיצת הידיים (TLS handshake) לבין תכונות זרימתיות (flow-based features) - מה שמאפשר סיווג מדויק ומהיר יותר גם כאשר מטא-נתונים רגישים מוסתרים על ידי ECH . בנוסף, אחד ההישגים הבולטים של המאמר הוא יצירת מסד נתונים רחב ומגוון של למעלה מ-600,000 זרימות TLS , שנאספו ממדינות בצפון אמריקה, אירופה ואסיה, מה שמעניק למחקר בסיס אמין וייצוגי.

אילו תכונות תעבורה המאמר משתמש ואילו מהן חדשות:

המאמר עושה שימוש בתכונות תעבורה שונות, אותן הוא מחלק לשלוש קטגוריות עיקריות:

תכונות חבילה:(packet-based features)

נתונים בלתי מוצפנים מתוך הודעות ה "ClientHello"-וה "ServerHello"-בפרוטוקול TLS כולל גרסת הפרוטוקול, קבוצות מפתחות (Groups), (Key Share) ורשימת צופן (Cipher Suites) .

שימוש באלגוריתם "Random Forest" לניתוח סדר ומבנה של התוספים (extensions) הבלתי מוצפנים שמועברים במהלך ההידוק הידיים.

תכונות זרימתיות:(flow-based features)

גדלי פקטות :(Packet Sizes - PS) סטטיסטיקות כמו מינימום, מקסימום, ממוצע וסטיית תקן של גדלי המנות הנשלחות והמתקבלות.

זמני הגעה בין פקטות :(Inter-Packet Times - IPT) מדידת זמני הגעה בין מנות רציפות והפקת מדדים סטטיסטיים כמו חציון, אחוזון 25 ו-75, וממוצע.

תכונות היברידיות:

שילוב התכונות החבילות והזרימתיות לכדי וקטור תכונות אחד שמוזן לאלגוריתם "Random Forest" שילוב זה מאפשר התחשבות הן במידע זמין מתוך ה TLS handshake-והן בדפוסים זרימתיים שמאפיינים סוגי תעבורה שונים.

החידוש המרכזי בא לידי ביטוי בכך שהאלגוריתם hRFTC מרחיב את היכולות של האלגוריתם הקודם "RB-RF", כך שיוכל להתמודד עם תעבורה של פרוטוקול "HTTP/3" המבוסס על "QUIC". בניגוד לשיטות אחרות, האלגוריתם החדש מתאים עצמו לתנאי ההצפנה המחמירים של ECH, תוך שמירה על מהירות ואמינות.

ממצאים מרכזיים ותובנות מהתוצאות:

שיפור משמעותי בדיוק הסיווג :האלגוריתם hRFTC הצליח להגיע לדיוק מרשים של 94.6% במדד ה F-score זאת בהשוואה לאלגוריתמים מבוססי TLS בלבד, שהשיגו דיוק של 38.4% בלבד. נתון זה מדגיש עד כמה חיוני לשלב בין תכונות זרימתיות ותכונות חבילות על מנת להשיג סיווג מדויק בתנאים של הצפנת ECH.

אי-יעילות של אלגוריתמים מבוססי TLS בלבד :התוצאות מצביעות על כך שהסתמכות בלעדית על תכונות TLS אינה מספיקה עוד לסיווג מדויק של תעבורה, בגלל העובדה שפרוטוקול ECH מצפין מטא-נתונים קריטיים כמו "Server Name Indication" (SNI). גם האלגוריתמים המתקדמים ביותר המתמקדים רק בנתונים החבילותיים התקשו להגיע לרמת דיוק גבוהה.

תלות גיאוגרפית :אחד הממצאים המרתקים של המחקר הוא ההשפעה המשמעותית של המיקום הגיאוגרפי על איכות הסיווג. האלגוריתמים שנאמדו על נתוני תעבורה שנאספו במדינה אחת התקשו לשמור על אותה רמת דיוק כאשר נוסו על נתוני תעבורה ממדינות אחרות. הדבר נובע מהבדלים במבנה הרשת, השימוש ב "Content Delivery Network" (CDN), ושינויים ברמת קיבוץ המנות.

גמישות בכמות נתונים :המחקר הדגים שיפור ניכר בגמישות האלגוריתם :hRFTC גם כאשר נעשה שימוש ב-10% בלבד ממסד הנתונים לצורך אימון, רמת הדיוק נותרה כמעט זהה לזו שהתקבלה כאשר נעשה שימוש ב-70% מהנתונים. נתון זה מצביע על יכולת ההכללה (generalization) המרשימה של האלגוריתם, המאפשרת יישום מהיר ויעיל גם במקרים שבהם כמות הנתונים הזמינים מוגבלת.

בס"ד

FlowPic: Encrypted Internet Traffic Classification is as Easy as Image Recognition

במאמר מספרים לנו על פיתוח גישה חדשנית לסיווג תעבורת אינטרנט מוצפנת על ידי שימוש בטכניקות עיבוד תמונה.

במקום להסתמך על שיטות מסורתיות של ניתוח תכונות סטטיסטיות, החוקרים מציעים להמיר את נתוני התעבורה לתמונות flowpics ולאחר מכן להשתמש ברשתות עצביות (CNN) לסיווג התמונות.

הגישה מאפשרת להבחין בדפוסים מורכבים בתעבורה שקשה לזהות בשיטות אחרות, במיוחד שהתעבורה מוצפנת.

המאמר מתמקד בתכונות תעבורה שקשורות לגודל וזמן (שהן בדר"כ זמינות גם בתעבורה מוצפנת).

החידוש המרכזי הוא אופן הניתוח של התכונות האלה.

כשנמיר תעבורה לתמונות flowpics, נוכל במקום לחלץ תכונות סטטיסטיות באופן ידני, להמיר את נתוני הזרימה לתמונה דו-ממדית כך שציר ה-X של התמונה מייצג את זמן ההגעה של "המנות" וציר ה-Y מייצג את הגודל. (כל פיקסל בתמונה מייצג את מספר המנות שהגיעו בטווח זמן מסוים וגודל מסוים).

לאחר יצירת התמונות נשתמש ברשתות CNN לסיווג, הרשתות האלה (CNN) ידועות ביכולתן ללמוד את הדפסים המורכבים בתמונות והן מתאימות במיוחד לזיהוי דפוסים בתעבורת הרשת.

התוצאות המרכזיות במאמר מוצגות מרשימות על סטים שונים של נתונים, כולל תעבורה מוצפנת באמצעות VPN (Virtual Private Network) ו-(Tor (The Onion Router.

בין היתר, דיוק גבוה בסיווג קטגוריות תעבורה (דיוק של 90%), יכולת טובה בזיהוי יישומים חדשים (יישומים שלא היו חלק מסט האימונים), ביצועים משופרים בהשוואה לעבודות קודמות (שהשתמשו בשיטות מסורתיות) ויכולת להתמודד עם בעיות סיווג מורכבות (כגון סיווג תעבורה מוצפנת וזיהוי יישומים חדשים).

השיטה הזו טובה במיוחד כי היא לא מסתמכת רק על תכונות סטטיסטיות שחולצו באופן ידני, אלא לוכדת דפוסים מורכבים בתבנית התעבורה על ידי יצירת ייצוג חזותי של זרמי תעבורה.

בנוסף היא יכולה לסווג תעבורה מוצפנת מבלי לפענח אותה (וזה שימושי מאוד לניתוח אבטחת רשת).

מסקנות סופיות:

המרת תעבורה לתמונות מאפשרת ללכוד דפוסים מורכבים שקשה לזהות בשיטות אחרות.

רשתות CNN הן כלי יעיל לסיווג תעבורת רשת, במיוחד כאשר התעבורה מוצפנת.

הגישה המוצעת היא בעלת פוטנציאל גבוה לשימוש ביישומי אבטחת רשת וניתוח תעבורה.

התוצאות מראות שהשיטה החדשה משיגה דיוק גבוה יותר בהשוואה לשיטות מסורתיות של ניתוח תכונות סטטיסטיות. בפרט, היא מאפשרת לזהות תעבורה מוצפנת גם כאשר אין גישה למידע החבילות עצמן.

בס"ד

Analyzing HTTPS Encrypted Traffic to Identify User's Operating System, Browser and Application

במאמר מסבירים לנו על תוקף חיצוני שיכול לזהות את - מערכת ההפעלה, האפליקציה והדפדפן דרך תעבורת הHTTPS המוצפנת שלו מבלי לפענח ולנתח את התעבורה עצמה, בעצם התוקף יכול לעשות זאת דרך הבנת התבנית של התעבורה ובעזרת אלגוריתמים וטכניקות של machine learning.

לפי המאמר זו פריצת דרך ראשונית שבעזרתה אפשר להבין על כל השלושה (מערכת ההפעלה, דפדפן והאפליקציה) מתנועה מוצפנת.

המאמר מציג תכונות חדשות לניתוח התעבורה המוצפנת שמבוססות על התנהגות SSL (Secure Sockets Layer) שזה פרוטוקול הצפנה ועל דפוסי תעבורה בולטים של הדפדפנים.

בין היתר למרות שהנתונים מוצפנים בHTTPS עדיין ניתן להפיק מידע מהמטא-דאטה של הנתונים, בגלל שכל מערכת הפעלה ודפדפן משתמשים בקונפיגורציות שונות של SSL נוכל להבדיל ביניהם.

(למשל, Chrome ו-Firefox תומכים בצופן שונה מאשר Internet Explorer, ומערכת Windows עשויה להתנהל אחרת מ-Linux בנוגע לניהול סשן SSL).

החוקרים השתמשו בכלי אוטומציה בשם Selenium כדי להפעיל דפדפנים וליצור תעבורה אמיתית.

הכלי SplitCap שימש לפיצול התעבורה לקבצים נפרדים לפי "sessions" (כל session מוגדר כ Tupple- <Protocol, IP source, IP destination, Port source, Port destination>).

המאמר מציג דיוק של 96.06% בזיהוי מערכת ההפעלה, הדפדפן והאפליקציה של המשתמש, על בסיס ניתוח תעבורת רשת מוצפנת (HTTPS).

המאמר מחלק את מאפייני התעבורה לשתי קטגוריות: מאפיינים בסיסיים (תכונות ממחקרים קודמים) ומאפיינים חדשים (תכונות שהוצגו במאמר זה ומשפרות את הדיוק).

המאפיינים הבסיסיים היו מספר חבילות נתונים (כמה נשלחו וכמה התקבלו), סך כל הנתונים (כמה מידע עבר בבתים), הפרשי זמן בין חבילות, פרמטרים של TCP ועוד.

המאפיינים החדשים היו בעיקר קשורים ל SSL ולדפוסי תעבורה בולטים, למשל מספר הרחבות (לכל דפדפן שיטות מימוש שונות), מספר שיטות הצפנה (סוגי האלג' להצפנה), אורך מזהה של הSession של SSL (שיכול להעיד על ההגדרות והפרוטוקולים של מערכת ההפעלה או הדפדפן).

בין היתר המאפיינים החדשים חשובים כי הם משפרים את הדיוק מאוד!, כלומר בעזרת השילוב המאפיינים הישנים והחדשים הגענו לדיוק כל כך גבוה.

תוצאות דיוק:

למאפיינים הבסיסיים: 93.51%, למאפיינים החדשים: ביצוע בר השוואה, למאפיינים החדשים והישנים ביחד: 96.06%.

זיהוי כמעט מושלם של מערכת ההפעלה, זיהוי בדיוק גבוה של הדפדפן (לפעמים טעות נניח בין chrome לsafari), וזיהוי אפליקציה שבגדול מדויק.

בדר"כ נצליח להבחין בין הדפדפנים בעזרת תבניתי התעבורה שלהם.

מסקנות סופיות:

הצפנת HTTPS היא לא מוגנת במלואה ולא שומרת לחלוטין על פרטיות המשתמש.

המאפיינים החדשים הנ"ל (SSL וBursty) עוזרים מאד לשפר את הדיוק.

תוקפים יכול למנף את הדבר למעקב, איתור ובחירת מטרה למתקפות סייבר.

בס"ד

חלק שלישי:

1. הקלטות(נמצא בתוך התיקייה question_3 תחת התיקייה recordings)
כדי להפחית רעש בתעבורה בזמן ההקלטות, נעשה כמה צעדים לפני תחילת ההקלטות:

נכבה עדכונים אוטומטיים, נסגור אפליקציות שלא קשורות למה שאנחנו בודקים ונכבה התראות במערכת.

*כמובן שיש בנוסף עוד הרבה צעדים שניתן לעשות כדי להפחית רעש

כאשר אנחנו גולשים באינטרנט/משתתפים בשיחת וידאו/וכו', התעבורה מוצפנת באמצעות TLS- דבר שיקשה על ניתוח המאפיינים שלה. TLS מצפין את התוכן של ההודעות, מה שגורם לכך שהwireshark מציג את הנתונים תחת "Encrypted Application Data" בלי לחשוף את התוכן שבפנים.

כדי לנתח את התעבורה ולהשוות בין מאפייני האפליקציות השונות (גלישה, סטרימינג ושיחות וידאו), אנחנו צריכים לפענח את ההצפנה של TLS ולחלץ את הנתונים. הדרך לעשות זאת היא באמצעות שמירת מפתחות ההצפנה(TLS Keys) . המפתחות האלה הם בעצם הסיסמאות שבעזרתן אפשר לפתוח את ההצפנה ולראות את התוכן המקורי.

נגדיר משתנה סביבה וקובץ לוג שלשם יתווספו המפתחות בכל פעם שנרצה להקליט(הקובץ נמצא בתיקייה (sslkeys_all-recordings).

2+3. לאחר שיש לנו את ההקלטות ואת המפתחות נרצה לפענח אותם- נכנס דרך הווירשארק להגדרת המסלול של המפתחות(אתם תצטרכו לעשות זאת גם אצלכם כי זה לא נשמר דרך הקלטות אלא במחשב עצמו- כמו צביעת חבילות).

דוגמא לפני שימוש במפתחות:

Application Data	180	TLSv1.3	35.186.224.26	192.168.100.93	6.690957	1070
Application Data	129	TLSv1.3	35.186.224.26	192.168.100.93	6.690989	1071
Application Data	384	TLSv1.3	35.186.224.26	192.168.100.93	6.691022	1072
Application Data	236	TLSv1.3	35.186.224.26	192.168.100.93	6.691053	1073
Application Data	148	TLSv1.3	35.186.224.26	192.168.100.93	6.691087	1074
Application Data	152	TLSv1.3	35.186.224.26	192.168.100.93	6.691117	1075
Application Data	189	TLSv1.3	35.186.224.26	192.168.100.93	6.691153	1076
Application Data	161	TLSv1.3	35.186.224.26	192.168.100.93	6.691186	1077
Application Data	217	TLSv1.3	35.186.224.26	192.168.100.93	6.691221	1078
Application Data	261	TLSv1.3	35.186.224.26	192.168.100.93	6.691255	1079
Application Data	175	TLSv1.3	35.186.224.26	192.168.100.93	6.691285	1080
Application Data	189	TLSv1.3	35.186.224.26	192.168.100.93	6.691315	1081
Application Data	145	TLSv1.3	35.186.224.26	192.168.100.93	6.691349	1082
Application Data	127	TLSv1.3	35.186.224.26	192.168.100.93	6.691382	1083
Application Data	127	TLSv1.3	35.186.224.26	192.168.100.93	6.691421	1084
Application Data	127	TLSv1.3	35.186.224.26	192.168.100.93	6.691455	1085
Application Data	127	TLSv1.3	35.186.224.26	192.168.100.93	6.691490	1086
Application Data	124	TLSv1.3	35.186.224.26	192.168.100.93	6.691527	1087
Application Data	127	TLSv1.3	35.186.224.26	192.168.100.93	6.691572	1088
Application Data	109	TLSv1.3	35.186.224.26	192.168.100.93	6.691597	1089
Application Data	486	TLSv1.3	35.186.224.26	192.168.100.93	6.691621	1090

אחרי:

/HEADERS[3]: PUT /clientsettings/api/v1	180	HTTP2	35.186.224.26	192.168.100.93	6.690957	1070
HEADERS[5]: GET /partner-userid/encrypted/branch	129	HTTP2	35.186.224.26	192.168.100.93	6.690989	1071
HEADERS[7]: PUT /connect-state/v1/devices/f2b2e90b09f34300bc5e0f5bb1f77000fe8db257	384	HTTP2	35.186.224.26	192.168.100.93	6.691022	1072
T /device-capabilities/v1/capabilities?device_type=computer&client_id=65b708073fc048	236	HTTP2	35.186.224.26	192.168.100.93	6.691053	1073
HEADERS[11]: GET /social-connect/v2/sessions/current?alt=protobuf	148	HTTP2	35.186.224.26	192.168.100.93	6.691087	1074
HEADERS[13]: GET /net-fortune/v2/fortune	152	HTTP2	35.186.224.26	192.168.100.93	6.691117	1075
HEADERS[15]: POST /collection/v2/delta	189	HTTP2	35.186.224.26	192.168.100.93	6.691153	1076
ERS[17]: POST /herodotus/spotify.resumption.v1.CurrentStateService/ListCurrentStates	161	HTTP2	35.186.224.26	192.168.100.93	6.691186	1077
OST /offline/v1/devices/532d312d352d32312d343931383937373434332d38323731373934363423d34	217	HTTP2	35.186.224.26	192.168.100.93	6.691221	1078
ET /playlist/v2/user/zw5eylo0bqgwz5d19jfxc8d9m/rootlist/diff?revision=40%2Cb7ae09128	261	HTTP2	35.186.224.26	192.168.100.93	6.691255	1079
OST /playback-settings/spotify.playbacksettings.PlaybackSettingsService/GetAllStored	175	HTTP2	35.186.224.26	192.168.100.93	6.691285	1080
ET /recently-played/v3/user/zw5eylo0bqgwz5d19jfxc8d9m/recently-played?limit=50&filte	189	HTTP2	35.186.224.26	192.168.100.93	6.691315	1081
HEADERS[27]: GET /playlist/v2/playlist/37i9dQZF1E8PCNhWgSecj3	145	HTTP2	35.186.224.26	192.168.100.93	6.691349	1082
HEADERS[29]: POST /collection/v2/delta	127	HTTP2	35.186.224.26	192.168.100.93	6.691382	1083
HEADERS[31]: POST /collection/v2/delta	127	HTTP2	35.186.224.26	192.168.100.93	6.691421	1084
HEADERS[33]: POST /collection/v2/delta	127	HTTP2	35.186.224.26	192.168.100.93	6.691455	1085
HEADERS[35]: POST /collection/v2/delta	127	HTTP2	35.186.224.26	192.168.100.93	6.691490	1086
HEADERS[37]: POST /collection/v2/delta	124	HTTP2	35.186.224.26	192.168.100.93	6.691527	1087
HEADERS[39]: POST /collection/v2/delta	127	HTTP2	35.186.224.26	192.168.100.93	6.691572	1088
DATA[3] (PROTOBUF)	109	…/HTTP2	35.186.224.26	192.168.100.93	6.691597	1089
DATA[7]	486	HTTP2	35.186.224.26	192.168.100.93	6.691621	1090

בצילומי המסך ניתן לראות את ההבדל בין תעבורה מוצפנת לפענוחה. בתמונה הראשונה, הנתונים מוצגים תחת "TLS Application Data" ללא מידע קריא, מה שמראה שהתוכן מוצפן. אחרי שהגדרנו קובץ מפתחות TLS ב Wireshark-ניתן לראות בתמונה השנייה כי התוכן מפוענח וכולל בקשות HTTP/2 כמו GET ו POST-כך אנחנו מראים כיצד ניתן לחשוף את התוכן אם מחזיקים במפתחות המתאימים, אך ללא מפתחות, הנתונים נותרים מוצפנים לחלוטין.

במהלך הניתוח Wireshark הצליח לפענח חלק מהחבילות, אך לא את כולן. הסיבה לכך היא ש TLS 1.3משתמש במפתחות זמניים. כמו כן, תעבורה המשתמשת בפרוטוקול QUIC לא ניתנת לפענוח, מכיוון שהיא לא משתמשת באותם מפתחות TLS הרגילים. לכן, למרות שהקלטנו מראש את מפתחות TLS חלק מהתעבורה עדיין נשארה מוצפנת ולא הייתה ניתנת לפענוח.

החלטנו **לא לסנן את החבילות שנשארו מוצפנות** ,מכיוון שזה היה משפיע על הדיוק של הגרפים. חבילות מוצפנות עדיין מכילות מידע חשוב כמו גודל החבילה וזמן ההגעה שלה, ולכן הן חשובות לניתוח סטטיסטי אמיתי. אם היינו מסננים רק את הנתונים הקריאים, היינו משנים את תבנית התעבורה של האפליקציות וגורמים להטיה בתוצאות. לכן, כדי להבטיח שהגרפים ישקפו את ההתנהגות האמיתית של התעבורה, השארנו גם את החבילות המוצפנות בניתוח שלנו.

הגרפים:

כדי להריץ את הקוד מצורף README עם מה שצריך להתקין.

לפני שנגיע לתוצאות של הגרפים נרצה לחשוב בעצמנו מה אנחנו מצפים לראות בכל גרף, נראה את הגרף ונסביר את התוצאה ומה שונה ממה שציפינו.

<u>נפח תנועה ממוצע לחבילה לכל אפליקציה:</u>

בגרף זה ניתן לראות את גודל החבילה הממוצע בכל אחת מהאפליקציות שנבדקו. ציפינו ששירותי סטרימינג כמו YouTube ו Spotify יכילו חבילות גדולות, מכיוון שהם מעבירים תוכן מדיה. בנוסף , דפדפנים כמו Chrome ו Edge אמורים להציג חבילות בגודל בינוני, מאחר שהם טוענים גם דפי אינטרנט וגם קבצי מדיה קטנים Zoom. היה צפוי להציג חבילות בגודל דומה ל YouTube כי שיחות וידאו אמורות לכלול חבילות גדולות.

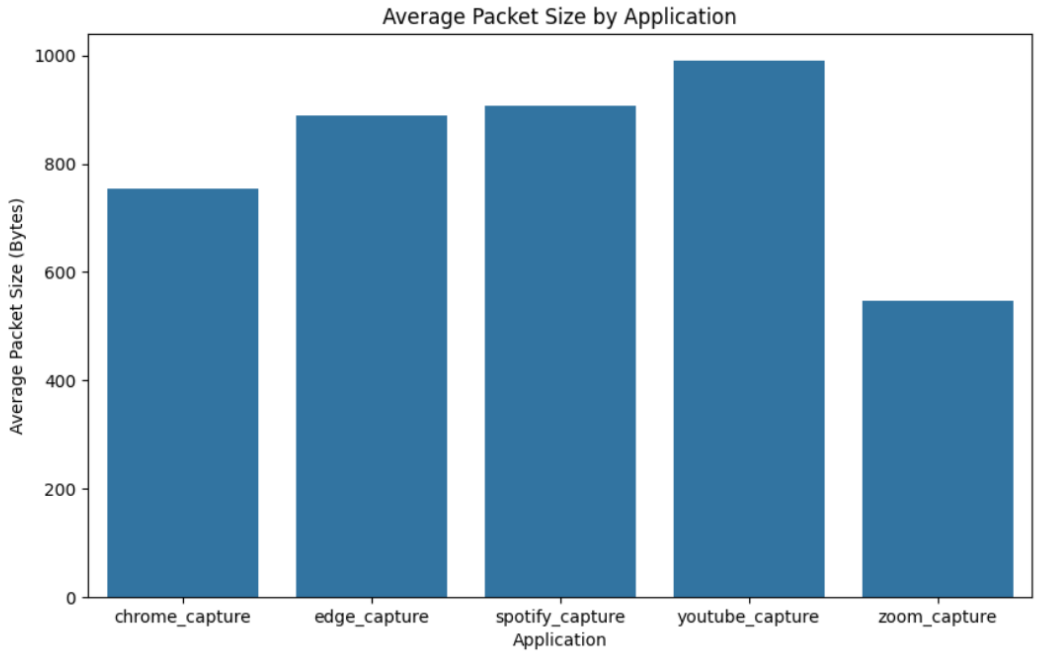

<u>מה יצא בפועל:</u>

התוצאות בפועל מראות ש YouTube אכן מכיל את החבילות הגדולות ביותר Spotify ו Edge מציגים חבילות בגודל בינוני, כפי שציפינו. לעומת זאת Zoom מציג חבילות קטנות יותר מהצפוי ,עם גודל ממוצע של כ-500 בייט, מה שלא תואם את ההנחה הראשונית שלנו.

גודל חבילות לפי אפליקציה:

הגרף מציג את ההתפלגות של גדלי החבילות עבור כל אפליקציה שנבדקה .ציפינו ששירותי סטרימינג כמו YouTube ו Spotify יציגו חבילות גדולות יותר בממוצע, מכיוון שהם מעבירים מדיה. Zoom היה צפוי להציג גם כן חבילות גדולות ,מאחר ששיחות וידאו דורשות העברת נתונים כבדה. Chrome ו-Edge היו צפויים להראות טווח גדול של גדלי חבילות ,מכיוון שגלישה כוללת בקשות קטנות (כמו טעינת דפי אינטרנט) וגם הורדות גדולות יותר של תוכן.

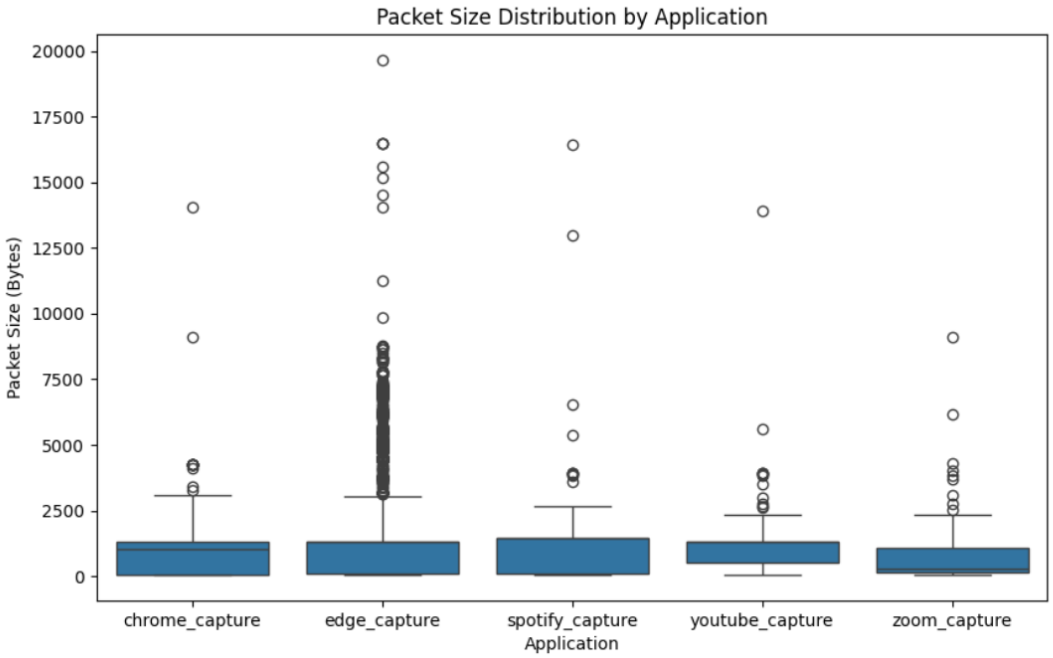

מה יצא בפועל:

בפועל, ניתן לראות שהתפלגות גדלי החבילות דומה מאוד בין כל האפליקציות ,כאשר רוב החבילות נמצאות בטווחים הנמוכים (מתחת ל-2000 בייט). Edge מציג חריגות רבות של חבילות גדולות בהשוואה לשאר האפליקציות.

מה שונה ממה שציפינו:

השוני העיקרי מהציפיות הוא בכך ששירותי סטרימינג כמו YouTube ו Spotify לא מציגים חבילות גדולות באופן קבוע ,אלא בעיקר חבילות קטנות עם מספר קטן של חריגות גדולות. Edge לעומת זאת, מציג הרבה חריגות של חבילות גדולות.

השוואת זמני הגעה בין חבילות:

גרף זה מציג את זמני ההגעה בין חבילות עבור כל אחת מהאפליקציות. ציפינו לראות ערכים נמוכים וקבועים בשירותים שמזרימים תוכן באופן רציף כמו YouTube ו Spotify מכיוון שהם שולחים חבילות באופן עקבי. לעומת זאת, בדפדפנים כמו Chrome ו Edge ציפינו לראות זמני הגעה משתנים יותר, בגלל שחבילות נשלחות בהתאם לטעינת דפים ולבקשות משתמש . Zoom היה צפוי להציג זמני הגעה נמוכים וקבועים יחסית, מכיוון ששיחות וידאו מחייבות זרימה רציפה של נתונים .

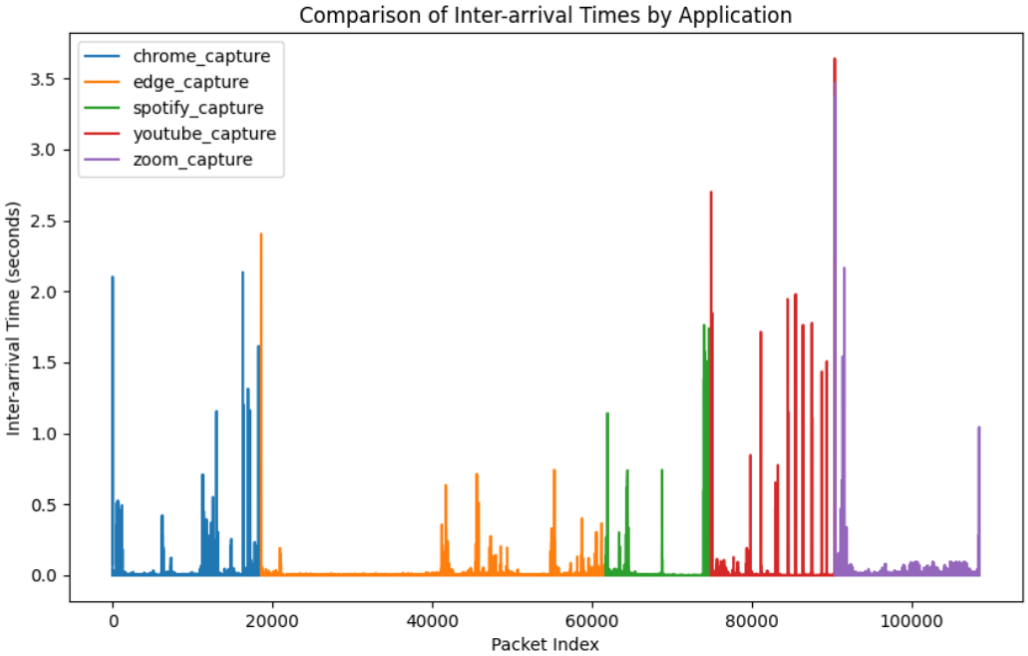

מה יצא בפועל:

בפועל Chrome (כחול) ו Edge(כתום) מציגים זמני הגעה לא אחידים עם קפיצות חדות ,בדיוק כפי שציפינו, משום שהתעבורה בדפדפנים תלויה בפעולות המשתמש. Spotify (ירוק) מציג זמני הגעה יחסית יציבים ,אך עם עליות מסוימות שמראות אולי שהתעבורה לא זורמת באופן מושלם. YouTube (אדום) מציג קפיצות משמעותיות בזמני ההגעה ,דבר שמצביע על כך שהוא אינו שולח חבילות ברצף אחיד, אלא מקבץ אותן במרווחים משתנים(יכול להיות בגלל buffer). Zoom (סגול) מציג דפוס שבו רוב הזמן זמני ההגעה נמוכים ויציבים.

מה שונה ממה שציפינו:

השוני העיקרי מהציפיות הוא בכך ש YouTube לא מציג זרימה חלקה כמו שחשבנו , אלא שולח חבילות בקבוצות עם הפסקות, כנראה בגלל טעינה מראש כפי שרשמנו למעלה. Spotify שומר על קצב יציב יותר ,אך עדיין לא אחיד לחלוטין. Zoom מציג קפיצות מפתיעות בהתחלה ובסוף שזה יכול להיות בגלל שזה לא היה בזמן השיחה עצמה אלא בקבלת הקישור וכניסה לשיחה וסיום השיחה

בס"ד

מספר פורטי מקור ייחודיים לפי אפליקציה:

הגרף מציג את מספר הפורטים הייחודיים ששימשו כ Source Port עבור כל אפליקציה .ציפינו שדפדפנים כמו Chrome ו Edge יציגו מספר גבוה של פורטים ייחודיים ,בגלל שכל חיבור חדש לאתר עשוי להשתמש בפורט מקור שונה. Spotify ו YouTube צפויים להציג מספר נמוך יותר של פורטים ,כי הם משתמשים לרוב בחיבורים מתמשכים(Persistent)

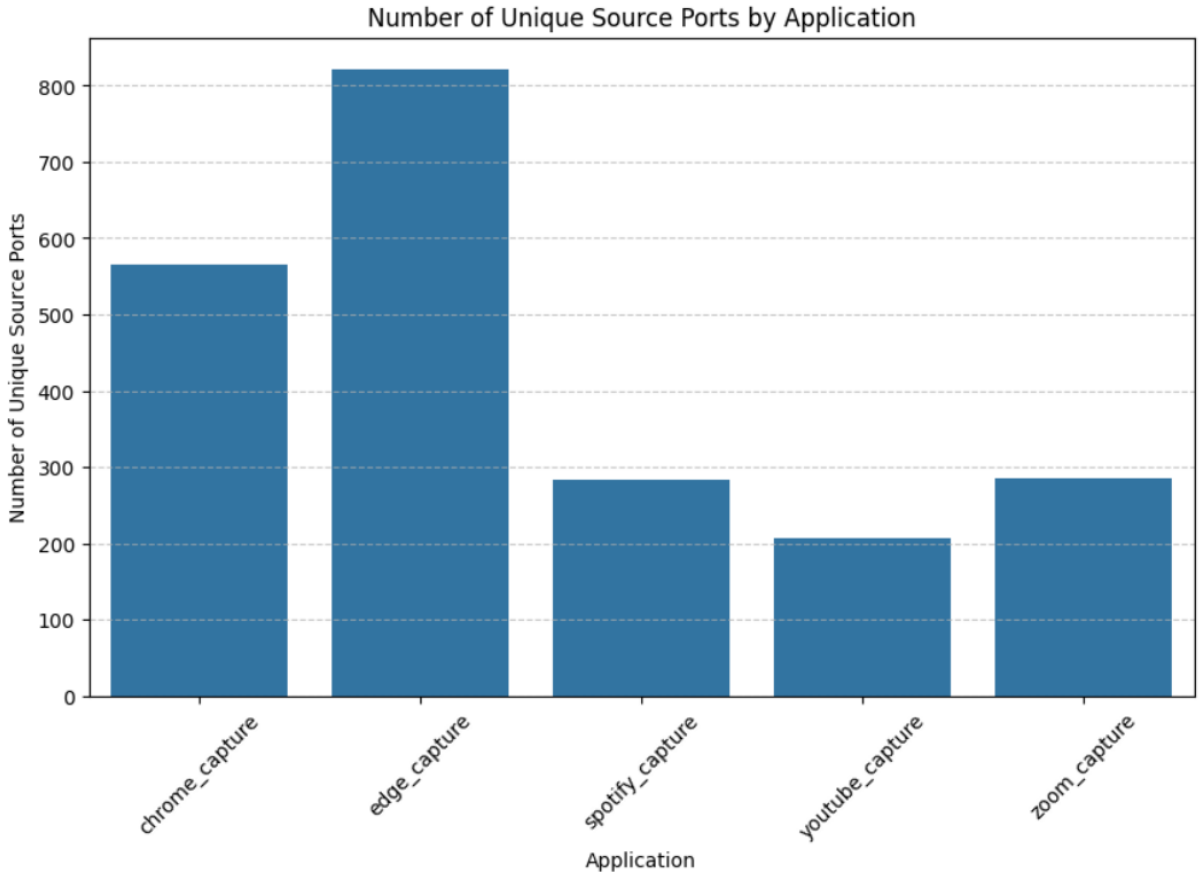

מה יצא בפועל:

בפועל, ניתן לראות כי Edge מכיל את מספר הפורטים הייחודיים הגבוה ביותר ,מה שמצביע על כך שהוא פותח חיבורים רבים עם פורטים משתנים. Chrome מציג גם מספר כי דפדפנים יוצרים חיבורים נפרדים לכל דף או שירות .Spotify ו YouTube מציגים מספר נמוך יחסית של פורטים ייחודיים ,מה שמעיד על כך שהתקשורת שלהם מבוססת על פחות חיבורים מתחלפים. Zoom מציג מספר בינוני של פורטים ייחודיים.

התפלגות דגלי TCP לפי אפליקציה:

נראה אילו דגלי TCP נפוצים בכל אפליקציה. למשל, אם אפליקציה מבצעת הרבה חיבורי TCP חדשים, ייתכן שנראה יותר דגל SYN אם יש הרבה סגירות חיבור, ייתכן שנראה יותר דגלי FIN

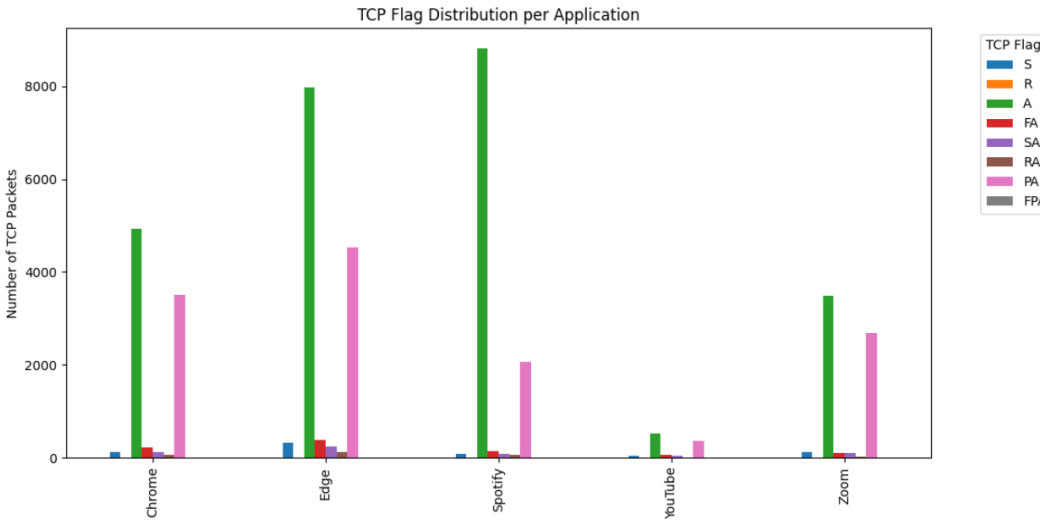

מה יצא בפועל:

בגרף רואים שבכל האפליקציות יש בעיקר שתי קבוצות עיקריות של דגלי TCP שמופיעות בתדירות גבוהה) ACK :המסומן בגרף A . וPSH/ACK-מסומן PA .

מה שונה ממה שציפינו:

ציפינו למצוא הרבה SYN וFIN-בחלק מהאפליקציות (במיוחד דפדפנים שפותחים וסוגרים חיבורים לעיתים קרובות), אך בפועל עיקר התעבורה מורכבת מחבילות ACK ו PSH/ACK,-כנראה מכיוון שרוב החיבורים נשארו פעילים לאורך זמן ולא נפתחו ונסגרו שוב ושוב.
אפליקציות כמו Zoom, Spotify ו Edge-מציגות נפח גדול של ACK כי הן מזרימות נתונים רציפים, מה שיוצר צורך רב באישורים(ACK). YouTube מציג מעט מאוד חבילות מכל סוג.

<u>מספר כתובות IP ייחודיות לפי אפליקציה:</u>

נראה כמה כתובות IP שונות כל אפליקציה מתקשרת איתן. לדוגמה, דפדפנים כמו Chrome ו Edge- נצפה שיציגו מספר גבוה של כתובות IP ייחודיות כי הם ניגשים לאתרים רבים, בעוד אפליקציות כמו Zoomאו Spotify עשויות לתקשר עם מספר קטן יחסית של שרתים קבועים.

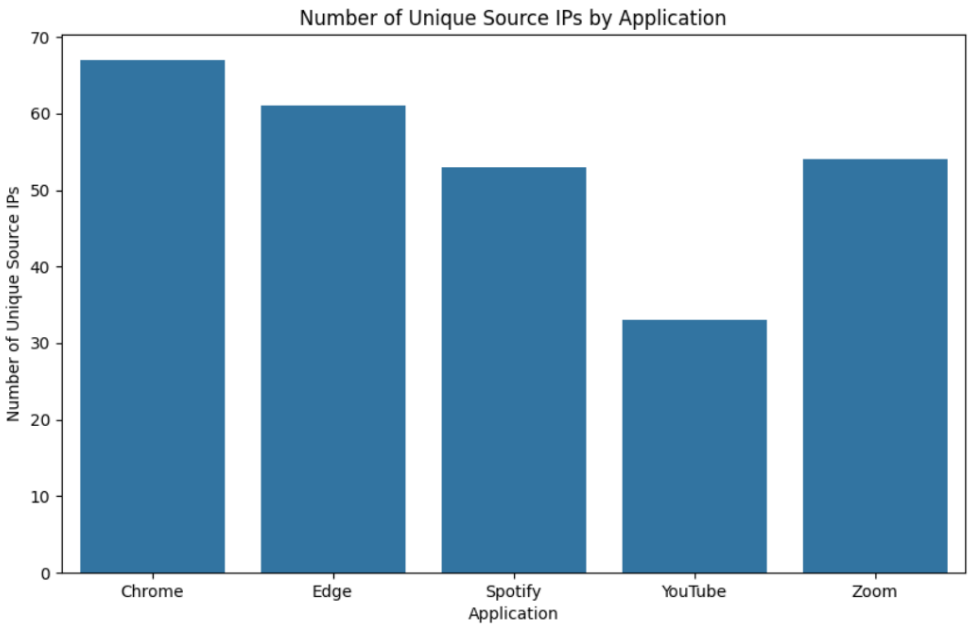

<u>מה יצא בפועל:</u>

Chrome מוביל עם הכי הרבה כתובות מקור ייחודיות (כ-70), אחריו Edge, ואז Spotify ו Zoom- במספרים מעט נמוכים יותר YouTube. מציג את המספר הנמוך ביותר של כתובות מקור ייחודיות.

4. המתקיף יכול לנסות לזהות את האפליקציות שהמשתמש השתמש בהן על ידי ניתוח של תבניות התעבורה ברשת. התהליך הזה יקרה גם אם התעבורה מוצפנת או כאשר אין לו גישה ישירה לתוכן של התעבורה, אבל הוא יכול ללמוד על דפוסי השימוש של האפליקציות על פי תכונות כמו גודל החבילות וחותמות הזמן.

Web surfing:
כשמדובר בגלישה באתרים באמצעות דפדפנים כמו Google Chrome או MS Edge המתקיף יוכל להבחין בכך שהתעבורה כוללת חבילות קטנות שמגיעות בפרקי זמן קצרים יחסית. חבילות קטנות עם הפסקות בין כל חבילה יכולות להעיד על גלישה באתרים שונים. לדוגמה, כל טעינת דף אינטרנט או תמונה תיצור חבילה קטנה מאוד. מכיוון שהדפדפנים השונים עשויים לשלוח בקשות HTTP/HTTPSעם תכנים שונים- תמונות, קבצי CSS, סקריפטים וכו -המתקיף עשוי לזהות את התעבורה הזו כגלישה באתרים, אך יהיה קשה לו להבחין אם מדובר ב Chrome-או MS Edge, כי חבילות התעבורה יהיו דומות מאוד.

Spotify:
בשירותים כמו Spotify המתקיף יוכל לזהות דפוסי תעבורה שמרמזים על סטרימינג של אודיו, מכיוון שהתעבורה תהיה רציפה ואחידה יותר לעומת גלישה רגילה באתרים. כל חבילה שתשלח תהיה בגודל בינוני או גדול יחסית, ותהיה תעבורה מתמשכת, כלומר חבילות ישלחו בצורה רציפה ללא הפסקות ארוכות. המתקיף יוכל לזהות כפעולה של סטרימינג אודיו, כי השירותים האלה שולחים מידע בצורה קבועה.

Youtube:
שירותים כמו YouTube דורשים כמות רבה מאוד של תעבורה כדי לשלוח וידאו באיכות טובה.
המתקיף יבחין בכך שהתעבורה כוללת חבילות גדולות מאוד שמגיעות בתבנית רציפה, כלומר חבילה אחרי חבילה. אם הוא יראה תעבורה שבה יש חבילות גדולות יחסית, בפרקי זמן קבועים, הוא יוכל להניח שמדובר בסטרימינג של וידאו, לדוגמה .YouTube כל שיחה או תנועה של סרטון תדרוש כמות רבה של נתונים, כך שהמתקיף יוכל להבין שמדובר בתעבורה שמיועדת להעברת וידאו. בנוסף, אם ישנן חבילות גדולות עם זמן קצר ביניהם, יתכן שזה יהיה יהיה סטרימינג וידאו.

Zoom:
אפליקציות כמו Zoom גם כן ידרשו תעבורה רציפה, אך היא תהיה שונה בסוגה. המתקיף יכול להבחין בכך שהתעבורה לא תהיה יציבה כמו סטרימינג של וידאו, אלא תשתנה לפי מספר המשתמשים והאיכות של השיחה. חבילות גדולות מאוד עשויות להופיע כשיש שיחה עם וידאו באיכות גבוהה, בעוד שבשיחה עם מספר מועט של אנשים ואיכות וידאו נמוכה יהיו חבילות קטנות יותר. המתקיף יוכל להבחין כי מדובר בתקשורת וידאו כאשר יש דפוסים של חבילות שמתפצלות למספר מקטעים בתוך פרקי זמן קצרים. הוא יכול גם לזהות תעבורה של אפליקציות כמו Zoom על פי החבילות הגדולות שנשלחות בצורה רציפה, ובסופו של דבר להבין שמדובר בשיחת וידאו.

כאשר משתמשים בשירותי אנונימיזציה כמו VPN או Tor התעבורה מוצפנת כך שהתוקף לא יכול לדעת לאילו אתרים או אפליקציות המשתמש מתחבר ישירות. בvpn כל החבילות עוברות דרך שרת מרכזי, כך שהתוקף רואה רק חיבור כללי ל VPN אך לא יודע מה היעד הסופי. בTOR החבילות מועברות דרך כמה שרתים מוצפנים, מה שמסתיר את המקור והיעד, אך עדיין משאיר דפוסי תעבורה שניתן לנתח. למרות שהתוקף לא רואה את כתובת ה IP של השרתים אליהם המשתמש מתחבר, הוא יכול לנסות לזהות את האפליקציה לפי דפוסי השידור .אם הוא רואה חבילות גדולות שנשלחות ברצף, הוא יכול להניח שמדובר בשירות סטרימינג כמו YouTube. אם החבילות קטנות ומופיעות עם הפסקות קצרות, זה עשוי לרמוז על גלישה באינטרנט. אם התעבורה קבועה לאורך זמן, ייתכן שמדובר בהזרמת אודיו כמו Spotify או שיחת וידאו zoom. מאחר שהתוקף עדיין יכול ללמוד מהמאפיינים הללו, ניתן להקשות עליו עוד יותר באמצעות טכניקות כמו ריפוד חבילות, טשטוש זמנים ושימוש

בפרוטוקולים כמו HTTP/2 שמערבבים זרמי תעבורה יחד .כך, גם אם התעבורה מוצפנת או אנונימית, יהיה קשה הרבה יותר לזהות איזו אפליקציה נמצאת בשימוש.

לסיכום ,למרות שהתוקף לא יכול לקרוא את התוכן עצמו ,הוא עדיין יכול ללמוד על סוג האפליקציה שבה נעשה שימוש על סמך גודל החבילות, זמני ההגעה ורציפות השידור .שימוש בהצפנה ובאנונימיזציה מקשה עליו מאוד, אבל לא תמיד מונע לחלוטין את הזיהוי.

נבנה מודל:

כפי שנאמר בפורום ניתן לקחת דאטה סט קיים ולעשות על זה מודל למידה.

ניקח דאטה שאושר לשימוש בפורום אשר מוזכר במאמר:
"FlowPic_Encrypted_Internet_Traffic_Classification_is_as_Easy_as_Image_Recognition" שבו מצוין הדאטה- "NonVPN-PCAPs"

מכיוון שהקלטות המקוריות (PCAP/PCAPNG) תופסות מקום רב(כ800 מ"ב), החלטנו לבצע את כל שלבי ההכנה המקדימים אצלנו ולספק לכם ישירות את הדאטה סט הסופי.
במקום להמיר מחדש את ההקלטות, תוכלו להריץ את הקוד הסופי ques_4.py על הדאטה סט המוכן (combined_dataset.csv), ולהגיע ישירות לשלב של אימון המודל ולחיזוי האפליקציות.

לצורך שקיפות ,צירפנו צילומי מסך שמראים את תהליך ההמרה.

בשלב הראשון של העבודה, לקחנו את ההקלטות מהאתר שנאמר לנו במאמר. ההקלטות שנלקחו היו בקבצי pcap/pcapng, הכוללים את תעבורת הרשת. כל קובץ כזה מכיל נתונים על פרמטרים שונים של חיבורי רשת. בעזרת הקוד שלנו "from_rec_to_dataset"המרנו כל אחת מההקלטות לקובץ csv. בכל קובץ ששמרנו, הוספנו עמודה חדשה בשם "Classification", שבה שומרים את קטגוריית האפליקציה של אותה הקלטה. הקטגוריות הוגדרו מראש, והשמות של ההקלטות שימשו כקטגוריות. כך, כל קובץ הומר לפורמט שניתן לעבוד איתו ולהתאימו לצרכים של ניתוח ולמידת מכונה. בנוסף, הוספנו עמודה חדשה בשם "Inter-Arrival Time" המחושבת כהפרש הזמן בין חבילה אחת לחבילה הבאה אחריה בתוך אותו זרם תעבורה. החלטנו להוסיף נתון זה, משום שבשאלה 4 התוקף יודע את חותמות הזמן (Timestamp) של החבילות, ולכן הוא יכול לחשב את ההפרשים בעצמו. מאחר שלכל אפליקציה יש דפוסי שליחת חבילות ייחודיים, מידע זה יכול לעזור בניתוח ולסייע לזיהוי האפליקציה גם כאשר התעבורה מוצפנת.

מצורף צילום של הקוד:

בס"ד

from_rec_to_dataset.py

```python
import os
import pandas as pd
from scapy.all import rdpcap
import hashlib

# Function to extract the classification (file name up to the underscore)
def extract_classification(file_name):  1 usage
    return file_name.split('_')[0]
# Function to create a hash of the 4-tuple
def hash_4tuple(source_ip, dest_ip, source_port, dest_port):  1 usage
    tuple_string = f"{source_ip}_{dest_ip}_{source_port}_{dest_port}"
    return hashlib.sha256(tuple_string.encode()).hexdigest()
# Function to convert a pcap file into a dataframe
def pcap_to_dataframe(pcap_file):  1 usage
    packets = rdpcap(pcap_file)
    data = []
    for packet in packets:
        if packet.haslayer('IP'):
            source_ip = packet['IP'].src
            dest_ip = packet['IP'].dst
            size = len(packet)
            timestamp = packet.time
            # Support both TCP and UDP
            if packet.haslayer('TCP'):
                source_port = packet['TCP'].sport
                dest_port = packet['TCP'].dport
            elif packet.haslayer('UDP'):
                source_port = packet['UDP'].sport
                dest_port = packet['UDP'].dport
            else:
                source_port = None
                dest_port = None
            # Create the hash of the 4-tuple (for scenario 1)
            flow_hash = hash_4tuple(source_ip, dest_ip, source_port, dest_port)
            # Add the data to the dataframe
            data.append([source_ip, dest_ip, size, timestamp, source_port, dest_port, flow_hash])
    df = pd.DataFrame(data,
                      columns=["Source IP", "Dest IP", "Size", "Timestamp", "Source Port", "Dest Port", "Flow Hash"])

    # Add classification category (file name up to the underscore)
    classification = extract_classification(os.path.basename(pcap_file))
    df['Classification'] = classification
    # Compute inter-arrival time (since attacker can infer it)
    df['Inter-Arrival Time'] = df.groupby('Flow Hash')['Timestamp'].diff().fillna(0)
    return df
# Function to process all pcap and pcapng files in the directory and save the dataset in the output directory
def process_pcap_files(input_dir, output_dir):  1 usage
    # Create the output directory if it doesn't exist
    if not os.path.exists(output_dir):
        os.makedirs(output_dir)
    all_files = os.listdir(input_dir)  # Get all files in the input directory
    pcap_files = [f for f in all_files if f.endswith((".pcap", ".pcapng"))]  # Filter only pcap and pcapng files
    # Print files that are not processed
    for filename in all_files:
        if not filename.endswith((".pcap", ".pcapng")):
            print(f"Skipping file (not pcap or pcapng): {filename}")
    # Process each pcap or pcapng file
    for filename in pcap_files:
        print(f"Processing file: {filename}")  # Print the current file name
        file_path = os.path.join(input_dir, filename)
        try:
            # Create the dataframe from the pcap file
```

```python
            # Create the dataframe from the pcap file
            df = pcap_to_dataframe(file_path)
            # Save the dataframe (single file for both scenarios)
            output_path = os.path.join(output_dir, f"{filename}.csv")
            df.to_csv(output_path, index=False)
            print(f"Saved dataset for {filename} to {output_path}")
        except Exception as e:
            print(f"Error processing {filename}: {e}")

# Call the function
input_directory = './NonVPN-PCAPs-01'  # Directory with pcap files
output_directory = './dataset'  # Directory to save the datasets

process_pcap_files(input_directory, output_directory)
```

לאחר המרת כל ההקלטות, בשלב השני השתמשנו בקוד "datasets_to_dataset" לאיחוד כל הקבצים שהומרו לדאטה סט אחד מאוחד. כל קובץ CSV נטען כ DataFrame נפרד, ולאחר מכן איחדנו את כל ה DataFrames לדאטה סט אחד גדול שמכיל את כל הנתונים. בשלב זה, ביצענו המרה של הערכים בעמודת ה "Classification"-למספרים על פי מילון שהוגדר מראש בקוד. המרת הקטגוריה למספרים מאפשרת לנו לעבוד עם תכונה זו בצורה נוחה יותר לצורך אימון המודל.
לדוגמה, קטגוריה כמו audio הומרה למספר 1, video למספר 2, וכן הלאה. כל קובץ שימש כקלט עם התכונות הרלוונטיות וקטגוריית הסיווג המומרת.

datasets_to_dataset.py

```python
import os
import pandas as pd
# Define the dictionary to map categories to numbers
category_map = {
    'aim': 1,
    'audio': 2,
    'chat': 3,
    'email': 4,
    'video': 5
}
# Function to process all CSV files in the dataset directory and combine them into one large dataframe
def combine_datasets(input_dir):  1 usage
    all_data = []
    # List all CSV files in the directory
    for filename in os.listdir(input_dir):
        if filename.endswith(".csv"):
            print(f"Processing file: {filename}")  # Print the current file being processed
            file_path = os.path.join(input_dir, filename)
            # Read the CSV file into a DataFrame
            df = pd.read_csv(file_path)
            # Skip empty files
            if df.empty:
                print(f"Skipping empty file: {filename}")
```

```python
                continue
            # Check if the Classification column exists
            if 'Classification' not in df.columns:
                print(f"Skipping file {filename} (missing Classification column)")
                continue
            # Convert classification category to a numeric value
            classification = df['Classification'].iloc[0].lower()
            category_number = category_map.get(classification, -1)  # Default to -1 if not found
            df['Classification'] = category_number
            # Append the dataframe to the list
            all_data.append(df)
    # If no valid data found, return None
    if not all_data:
        print("No valid data found in the dataset directory.")
        return None
    # Concatenate all dataframes into one large dataframe
    combined_df = pd.concat(all_data, ignore_index=True)
    return combined_df
# Function to save the combined dataframe as a single CSV
def save_combined_dataset(output_dir, combined_df):  1 usage
    if combined_df is None or combined_df.empty:
        print("No data to save. Exiting.")
        return
    # Save full dataset in the same directory as this script
    output_path = os.path.join(output_dir, 'combined_dataset.csv')
    combined_df.to_csv(output_path, index=False)
    print(f"Saved the combined dataset to {output_path}")

# Path to the directory containing the individual dataset files
input_directory = './dataset'  # The directory where the individual CSV files are stored
output_directory = './'  # Save the final dataset in the same directory as this script
# Combine the datasets and save the result
combined_df = combine_datasets(input_directory)
save_combined_dataset(output_directory, combined_df)
```

לאחר שיצרנו דאטה סט אחד מאוחד עם קטגוריות מומרות למספרים, בשלב השלישי השתמשנו בקוד ques_4 לאימון המודל ולחיזוי הקטגוריות. המודל שבחרנו לאימון היה Random Forest משום שהוא מסוגל להתמודד בצורה טובה עם בעיות סיווג לא ליניאריות, כמו אלו שמצאנו בתכונות שהיו לנו. בעזרת Random Forest, האימון על הדאטה אפשר למודל ללמוד את הדפוסים בין התכונות השונות ולחזות את קטגוריית האפליקציה על פי תעבורת הרשת. המודל הופעל על דאטה של אימון ובדיקה, ולאחר האימון ביצענו חיזוי עבור קבוצת הבדיקה והערכנו את ביצועי המודל באמצעות מדדי דיוק.

Random Forest מבוסס על יצירת מספר עצי החלטה שלכל אחד מהם יש גישה עצמאית ומגוון החלטות שיכולות לזהות דפוסים לא ליניאריים בצורה טובה. כל עץ בודק את הנתונים באופן אקראי ומספק תחזית שונה, ובסופו של דבר אנחנו מאחדים את תוצאות כל העצים כדי לקבל תוצאה מדויקת יותר.

הפשטות והגמישות של Random Forest מאפשרות לנו להשתמש בו בקלות יחסית מבלי צורך בהתאמות מורכבות. כל אלו יחד הופכים את המודל לאופציה הטובה ביותר לפרויקט הזה, שבו אנחנו מנסים לחזות קטגוריות של אפליקציות או סוגי תעבורה ברשת.

תוצאות:

```
Accuracy for Case 1 (Flow ID included): 0.9825
Accuracy for Case 2 (Without Flow ID): 0.9671
```